

TÓPICOS EM ESTATÍSTICA I

Prof° Guilherme Rodrigues

# REDES NEURAIS RECORRENTES

Allan Faria
Davi Guerra
Gustavo Garcia

# O QUE É.

Uma Recurrent Neural Network (RNN) é uma arquitetura de Rede Neural que processa dados sequenciais, como palavra por palavra em uma frase ou informações através do tempo.

Algo notável na RNN é que o tamanho das sequências processadas é independente, não precisando ter um tamanho fixo para poder ajustar a rede.


## TIPOS DE DADOS.

Séries temporais: finanças, previsão climática.

Textuais: tokenização, one-hot encoding, embedding.

Sons: reconhecimento de fala.

Outros, como dados biológicos (eletrocardiogramas, sequenciamento genético)




### TIPOS DE ARQUITETURA.


one to many many to one many to many many to many one to one Legendas Análise de Tradução Sintetização para imagens de voz sentimento

### POR DENTRO DA RNN.

### RNN State Update and Output




Compartilhamento de parâmetros



### FEEDFOWARD.


RNNs: Computational Graph Across Time






### BACKPROPAGATION.

### RNNs: Backpropagation Through Time








#### Vanilla RNN Gradient Flow

Bengio et al, "Learning long-term dependencies with gradient descent is difficult", IEEE Transactions on Neural Networks, 1994 Pascanu et al, "On the difficulty of training recurrent neural networks", ICML 2013



## GRADIENTS ISSUES.


# explosion

- 1. ato de explodir, expansão muito alta. na matemática, multiplicação de matrizes podem resultar em explosão dos valores.
- 2. pode ser solucionado usando gradients clipping

### vanish


ato de limpar, encolher, diminuir até ser insignificante.
na matemática, multiplicação de matrizes podem
resultar em limpeza dos valores.






g <- c \*g/||g||

#### Aqui em Curitiba faz ...



Short term dependency

# Nasci no Brasil, sou negro, tenho 19 anos, gosto de pizza, minha língua materna é o ....




Long term dependency


- 1 Mudar a função de ativação
- 2 Parâmetros de Inicialização
- 3 Gates



### LSTM & GRU.

#### **LONG-SHORT TERM MEMORY**





### Cell State


Avenida. Memória.

### Gates

Esquecer. Renovar. Absorver. Transmitir.




#### **FORGET GATED**



- C<sub>ist</sub> previous cell state
- forget gate output

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$

#### **UPDATE GATED**




- c<sub>101</sub> previous cell state
- forget gate output
- input gate output
- c candidate

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] + b_i\right)$$


$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

#### **CELL STATE**



- previous cell state
- forget gate output
- input gate output
- candidate
- new cell state


#### **OUTPUT GATE**



- previous cell state
- forget gate output
- input gate output
- candidate
- new cell state
- output gate output
- hidden state


$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right)$$

$$h_t = o_t * \tanh(C_t)$$






## GRU





- 1. quem vai e quem fica.
- 2. treinamento gera inclusão, não exclusão.








### ALGORITMOS DE RNN.

- Arquiteturas de RNNs em problemas generalizados: NLP, Distribuições em relação ao tempo...
- Aprendizado da rede conforme a arquitetura


# RNN LAYER ESTADO.

#### Retorna estado




# RNN LAYER SEQUÊNCIA.

### Retorna SEQUÊNCIA.




### SEQUENCE TO VALUE.

### **SEQ-2-VALUE**




# SEQUENCE TO SEQUENCE. Recursive RNN

#### **Recursive RNN**




# SEQUENCE TO SEQUENCE Encoder-Decoder.

#### **Encoder-Decoder**



# RNN LAYER BIDIRECIONAL.

#### **BIDIRECIONAL**




## ATENÇÃO.


 Mecanismo de rankeamento de sequências. Mais usados em Encoder-Decoder

 Performance nas relações e no aprendizado


### Sem atenção




### Com atenção



### Attention is all you need



### Attention is all you need



$$oldsymbol{c}_t = \sum_s lpha_{ts} ar{oldsymbol{h}}_s$$

$$\alpha_{ts} = \frac{\exp\left(\operatorname{score}(\boldsymbol{h}_t, \bar{\boldsymbol{h}}_s)\right)}{\sum_{s'=1}^{S} \exp\left(\operatorname{score}(\boldsymbol{h}_t, \bar{\boldsymbol{h}}_{s'})\right)}$$


$$\operatorname{score}(m{h}_t, ar{m{h}}_s) = egin{cases} m{h}_t^ op m{W} ar{m{h}}_s \ m{v}_a^ op anh \left(m{W}_1m{h}_t + m{W}_2ar{m{h}}_s
ight) \end{cases}$$

### TEACHER FORCING.

#### **TEACHER FORCING**

• Melhor desempenho em aprender

"Start na vida do neurônio"



## Teacher forcing **DECODER** <G0> Output RNN (Input) **ENCODER**

LAB

